


DETECÇÃO DE ANOMALIAS CARDIOLÓGICAS EM ECG



Rafael Paz
João Pedro Barbosa
Vinicius Lima
Marcelo Arcoverde
Daniel Silvestre

SUMÁRIO

1. INTRODUÇÃO
2. PRÉ-PROCESSAMENTO
3. EXTRAÇÃO DE CARACTERÍSTICAS
4. MODELO DE CLASSIFICAÇÃO
5. RESULTADOS
6. CONCLUSÃO

INTRODUÇÃO

INTRODUÇÃO

Dataset

[Share](#)[About](#)[Explore](#) [Database](#)[Open Access](#)

PTB-XL, a large publicly available electrocardiography dataset

Patrick Wagner  , Nils Strodthoff  , Ralf-Dieter Bousseljot  , Wojciech Samek  , Tobias Schaeffter 

Published: Nov. 9, 2022. Version: 1.0.3

INTRODUÇÃO

Escolha das doenças

O GLOBO 100 | Saúde

O GLOBO 100 | Política | Brasil | Rio | Mundo | Economia | Saúde | Cultura | Esportes | Colunistas | Clube | Newsletters

Saúde

‘Estamos vivendo uma epidemia de arritmias cardíacas’, alerta cardiologista Eduardo Saad

Especialista, que toma posse na Academia Nacional de Medicina na próxima sexta-feira, explica o quadro que está por trás de grande parte dos casos de morte súbita

Por **Bernardo Yoneshigue** —
14/05/2025 04h30 · Atualizado há 2 me:


 Ministério da Saúde



Article

Automated Detection of Myocardial Infarction and Heart Conduction Disorders Based on Feature Selection and a Deep Learning Model

Mohamed Hammad ¹, Samia Allaoua Chelloug ^{2,*}, Reem Alkanhel ², Allam Jaya Prakash ³,
Ammar Muthanna ⁴, Ibrahim A. Elgendy ⁵ and Paweł Plawiak ^{6,7,*}



O **Infarto Agudo do Miocárdio** é a maior causa de mortes no país. Estima-se que, no Brasil, ocorram de **300 mil a 400 mil** casos anuais de infarto e que a cada **5 a 7** casos, ocorra um óbito. Para diminuir o risco de morte, o atendimento de **urgência e emergência**, nos primeiros minutos, é fundamental para salvar uma vida.

INTRODUÇÃO

Doenças escolhidas: Infarto do miocárdio e distúrbio de condução


Pré-processamento dos dados

Extração de características

Divisão dos dados

Obtenção das melhores features

Modelo




PRÉ PROCESSAMENTO


PRÉ PROCESSAMENTO DO DATASET

1. MAPEAMENTO DE CLASSE PARA SUPERCLASSE DE DOENÇA
2. ESCOLHA DAS SUPERCLASSES DE INTERESSE
3. ESCOLHA DE PACIENTES COM APENAS 1 DIAGNÓSTICO
4. ESCOLHA DE COLUNAS DE INTERESSE: IDADE, SEXO, PATH DO ECG E SUPERCLASSE (NORM, MI, CD)
5. ESCOLHA DOS CANAIS DO ECG

PRÉ PROCESSAMENTO DO DATASET



PRÉ PROCESSAMENTO DO DATASET




PRÉ PROCESSAMENTO DO SINAL

1. ESPELHAMENTO DO SINAL
2. FILTRO PASSA ALTA
3. FILTRO NOTCH
4. FILTRO DE RUÍDO COM WAVELET


PRÉ PROCESSAMENTO

FILTRO PASSA-ALTA




PRÉ PROCESSAMENTO

FILTRO NOTCH OU REJEITA-BANDA




PRÉ PROCESSAMENTO

FILTRO NOTCH




PRÉ PROCESSAMENTO

FILTRO DE RUÍDO COM WAVELET



PRÉ PROCESSAMENTO

ESPELHAMENTO DO SINAL



EXTRAÇÃO DE CARACTERÍSTICAS


EXTRATORES DE CARACTERÍSTICAS

1. EXTRAÇÃO DE FEATURES VIA INTERVALOS
2. DENSIDADE DE ENERGIA ESPECTRAL

EXTRATORES DE CARACTERÍSTICAS


EXTRAÇÃO DE FEATURES VIA INTERVALOS

1. Detecção do pico R (SciPy)
2. Detecção de outros picos (P, Q, S, T, QRS) a partir do pico R através de janelas fisiológicas
3. Obtenção de medidas morfológicas e estatísticas a partir dos picos (média, duração...)





EXTRATORES DE CARACTERÍSTICAS

EXTRAÇÃO DE FEATURES VIA INTERVALOS



EXTRATORES DE CARACTERÍSTICAS

EXTRAÇÃO DE FEATURES VIA INTERVALOS




EXTRATORES DE CARACTERÍSTICAS

DENSIDADE DE ENERGIA ESPECTRAL

Cálculo da energia em diferentes bandas:

- Baixa Frequência (0,5–4) Hz → contém parte do complexo P/T e contribuições lentas.
- Média Frequência (4–15) Hz → concentra a maior parte da energia do complexo QRS.
- Alta Frequência (15–40) Hz → contém detalhes de alta frequência do QRS.





MODELO DE CLASSIFICAÇÃO

MODELO DE CLASSIFICAÇÃO

ENCONTRANDO MELHORES FEATURES


- Random Forest



- Random Forest avalia a importância de cada feature com base em quanto ela ajuda a separar as classes ao longo das árvores do modelo.
- Selecionamos as features com maior score de importância, ou seja, aquelas que mais contribuem para a distinção entre classes.

MODELO DE CLASSIFICAÇÃO


SVM



- SVM classifica os pontos buscando separação linear entre as classes.
- Para dados não linearmente separáveis, aplica-se uma função kernel, projetando os dados em outra dimensão para permitir a separação.
- Para classificação multiclasse, o SVM realiza várias divisões “uma classe vs. todas as outras”.

MODELO DE CLASSIFICAÇÃO


DIVISÃO CONJUNTO DE DADOS



- Para o treinamento do modelo, o dataset foi dividido em conjunto de treinamento e conjunto de teste, sendo 80% dos dados destinados ao treinamento e 20% ao teste.
- Do conjunto de treinamento, 20% dos dados foram separados para formar o conjunto de validação.
- O conjunto de validação foi utilizado para o ajuste dos hiperparâmetros, como a função kernel, o parâmetro gamma e o tipo de balanceamento.
- Já o conjunto de teste foi utilizado após o ajuste dos hiperparâmetros para avaliar o desempenho do modelo

MODELO DE CLASSIFICAÇÃO

BALANCEAMENTO DO MODELO



- Como nosso conjunto de dados era bem desbalanceado, utilizamos o parâmetro de balanceamento de classe do scikit-learn, que adiciona um peso para cada classe.
- O que evita que nosso modelo apenas preveja bem uma única classe


MODELO DE CLASSIFICAÇÃO

NORMALIZAÇÃO DOS DADOS

- O SVM se baseia em distâncias entre os pontos para traçar o hiperplano de separação.
- Se algumas features tiverem valores muito grandes, elas dominam a distância, fazendo com que outras features tenham menos influência no modelo.
- Para resolver esse problema, utilizamos o StandardScaler da biblioteca scikit-learn, que normaliza as features para escalas comparáveis.


RESULTADOS

RESULTADOS



RESULTADOS

TREINAMENTO



RESULTADOS

MÉTRICAS DE AVALIAÇÃO

- **Precision**: É o número de exemplos que o modelo previu como positivos e acertou dividido pelo número total de exemplos que ele previu como positivos.
- **Recall**: É o número de pessoas que o modelo identificou corretamente como tendo a doença dividido pelo número total de pessoas que realmente têm a doença nos seus dados.
- **F1 Score**: É a média harmônica entre a precisão e o recall. A média harmônica é usada porque ela dá mais importância a valores baixos.

RESULTADOS

MÉTRICAS DE AVALIAÇÃO

$$Precisão = \frac{Positivos\ Verdadeiros}{Positivos\ Verdadeiros + Falsos\ Positivos}$$

$$Recall = \frac{Positivos\ Verdadeiros}{Positivos\ Verdadeiros + Negativos\ Falsos}$$

$$F1\ Score = 2 * \frac{Precisão * Recall}{Precisão + Recall}$$


RESULTADOS

TREINAMENTO

	precision	recall	f1-score	support
CD	0.76	0.72	0.74	219
MI	0.63	0.55	0.58	278
NORM	0.90	0.93	0.91	1437
accuracy			0.85	1934
macro avg	0.76	0.73	0.74	1934
weighted avg	0.84	0.85	0.85	1934

RESULTADOS

TESTE





	precision	recall	f1-score	support
CD	0.73	0.70	0.72	274
MI	0.65	0.65	0.65	348
NORM	0.91	0.92	0.91	1795
accuracy			0.85	2417
macro avg	0.76	0.76	0.76	2417
weighted avg	0.85	0.85	0.85	2417

CONCLUSÃO

CONCLUSÃO

- Boa generalização.
- Não teve uma acurácia tão boa para Infarto do Miocardio, mas teve uma boa para Distúrbio de Condição.
- Bom para triagem.



OBRIGADO!

