

# DETECÇÃO DE ANOMALIAS CARDIOLÓGICAS COM ECG


Daniel Silvestre de Franca e Souza , Joao Pedro Barbosa Marins ,  
Marcelo Arcoverde Neves Britto de Rezende , Rafael Paz Fernandes ,  
Vinicius Lima Sa de Melo

## Introdução

O presente projeto tem como objetivo o desenvolvimento de um modelo capaz de realizar o diagnóstico automático de anomalias cardíológicas a partir de eletrocardiogramas (ECGs). Para isso, foi utilizado o dataset PTB-XL [1], que contém mais de 21.000 amostras de ECGs com duração de 10 segundos, registradas em frequências de amostragem de 100 Hz e 500 Hz. O conjunto de dados também inclui dois arquivos no formato CSV: o primeiro contendo informações dos pacientes, como nome, idade, sexo e o caminho para os respectivos sinais de ECG; e o segundo descrevendo todas as possíveis doenças presentes nos diagnósticos, bem como suas superclasses correspondentes.

A proposta do trabalho consistiu em utilizar este dataset para treinar e validar um modelo de classificação capaz de identificar tanto corações normais quanto casos de anomalias específicas. Para a definição das classes alvo, optou-se por focar em infarto do miocárdio e distúrbio de condução. Essa escolha foi motivada pela gravidade clínica dessas condições e pela sua alta prevalência na população, conforme evidenciado por estudos e reportagens recentes [2,3,4]. Assim, buscou-se desenvolver uma solução que, além de tecnicamente consistente, pudesse ter relevância prática no apoio ao diagnóstico médico.

## Resumo



O desenvolvimento do projeto seguiu etapas estruturadas para garantir a qualidade dos dados e a robustez do modelo de classificação. Inicialmente, foram mapeadas as superclasses de doenças presentes no dataset e selecionadas as colunas relevantes, incluindo dados dos pacientes e sinais de ECG. Em seguida, aplicaram-se filtros aos sinais, como o passa-alta, para corrigir a baseline e reduzir ruídos, preparando os dados para análises subsequentes.

Na etapa de extração de features, os sinais foram analisados nos domínios do tempo e da frequência. No domínio do tempo, foram extraídos atributos relacionados a intervalos e durações das ondas P, Q, R, S e T, enquanto no domínio da frequência foram calculadas métricas como a energia nas bandas de baixa, média e alta frequência, fornecendo informações complementares sobre a atividade cardíaca.

O conjunto de dados foi então dividido em treinamento, validação e teste, destinando-se 20% das amostras ao teste e 80% ao treinamento, com 20% deste último separado para validação. Essa divisão permitiu ajustar hiperparâmetros do modelo e reduzir o risco de overfitting.

Após a partição, utilizou-se o Random Forest para identificar as features mais importantes, garantindo que apenas as variáveis mais relevantes fossem consideradas no classificador final. As features selecionadas foram então normalizadas, ajustando todas as variáveis a uma escala uniforme, o que é essencial para o funcionamento do SVM.

Por fim, os dados normalizados foram processados por um SVM com abordagem um contra um para classificação multiclasse, responsável por realizar a predição das amostras de teste. O modelo demonstrou capacidade de identificar com eficácia as anomalias cardíacas selecionadas — infarto do miocárdio e distúrbios de condução —, evidenciando a viabilidade da metodologia adotada para diagnóstico automatizado com base em ECG.

## **Metodologia**

### **Pré-processamento**

O processo de pré-processamento constituiu uma etapa essencial para a preparação dos dados antes da extração de características e do treinamento dos modelos de classificação. Essa fase envolveu tanto o tratamento das informações contidas nos arquivos de metadados do dataset PTB-XL quanto o processamento direto dos sinais de ECG.

No que diz respeito aos metadados, iniciou-se com o mapeamento das classes de doenças para suas respectivas superclasses, conforme definido na documentação do dataset. Esse mapeamento foi necessário para organizar e padronizar as categorias de diagnóstico. Em seguida, procedeu-se ao descarte das superclasses não utilizadas no escopo do projeto, de forma a manter apenas as relacionadas ao infarto do miocárdio e ao distúrbio de condução, além da classe referente a corações normais.

A partir disso, foram selecionadas apenas as colunas relevantes dos dados dos pacientes, especificamente idade e sexo, por serem atributos potencialmente correlacionados com a ocorrência de determinadas doenças cardíacas e que poderiam contribuir para o desempenho do modelo. Além disso, realizou-se a remoção de pacientes com mais de um diagnóstico, a fim de evitar ambiguidades na rotulação das instâncias e, consequentemente, reduzir o risco de introduzir ruídos no treinamento. Por fim, foi feita a seleção dos canais desejados do ECG — II, aVL, aVF, V1, V2 e V5 [5] — escolhidos por sua relevância clínica e potencial para representar de forma abrangente a atividade elétrica cardíaca.

No que se refere ao tratamento dos sinais de ECG, o primeiro procedimento adotado foi o espelhamento do sinal nas extremidades. Essa técnica visou corrigir distorções presentes no início e no final do traçado, as quais podem ocorrer devido ao funcionamento dos filtros digitais que utilizam amostras passadas e/ou futuras para o cálculo.

Posteriormente, foram aplicados diferentes filtros para corrigir problemas específicos:

- **Filtro Passa-Alta:** utilizado para remover a variação lenta da linha de base (*baseline wander*), frequentemente causada por movimentos do paciente ou variações na impedância de contato dos eletrodos.
- **Filtro Notch** (ou rejeita-faixa): aplicado para eliminar o ruído da rede elétrica, especificamente em 50 Hz, frequência de sistemas elétricos de países europeus, de onde se originam os dados do PTB-XL.

$$H(s) = \frac{s^2 + w_0^2}{s^2 + w_c s + w_0^2}$$

Função de transferência do filtro Notch


- **Filtro de ruído com Wavelet:** empregado para a remoção de ruídos de alta frequência e artefatos de natureza não periódica, sem comprometer a integridade das ondas características do ECG, como P, QRS e T.

Essa sequência de operações garantiu que os sinais utilizados nas etapas posteriores estivessem limpos, padronizados e com mínima interferência de artefatos, maximizando a confiabilidade do processo de extração de características e treinamento dos modelos.

## Extração de Features

A etapa de extração de características foi fundamental para transformar os sinais brutos de ECG, previamente pré-processados, em um conjunto estruturado de atributos capazes de representar de forma quantitativa as informações fisiológicas relevantes. Essa fase buscou capturar tanto aspectos morfológicos no domínio do tempo quanto informações espectrais no domínio da frequência, de modo a fornecer ao modelo de aprendizado de máquina um panorama abrangente do funcionamento cardíaco.


A primeira abordagem adotada foi a extração baseada em intervalos, utilizando a biblioteca SciPy para a detecção automática dos picos R. A partir desses picos, foram definidas janelas fisiológicas que permitiram a identificação das demais ondas do ciclo cardíaco — P, Q, S e T —, assim como a delimitação do complexo QRS. Com base nessa segmentação, foram calculadas diversas medidas morfológicas e estatísticas:



- **Features estatísticas:**
  - mean\_rr\_interval, std\_rr\_interval
  - mean\_qq\_interval, std\_qq\_interval
  - mean\_qrs, std\_qrs
- **Features morfológicas:**
  - q\_amplitude, q\_duration, q\_area, q\_pathologic\_ratio
  - r\_amplitude, r\_duration, r\_area
  - s\_amplitude, s\_duration, s\_area
  - t\_amplitude, t\_duration, t\_area, t\_inversion, t\_r\_ratio
  - q\_r\_ratio, r\_s\_ratio
- **Segmento ST:**
  - st\_elev\_mean, st\_elev\_std
  - st\_depression
  - st\_dur\_mean, st\_dur\_std
  - st\_slope\_mean, st\_slope\_std
  - st\_area
- **Intervalos Clínicos:**
  - qt\_interval, qt\_dispersion, qtc\_interval
  - jt\_interval

A segunda abordagem correspondeu à análise espectral do sinal. Foi realizada a Transformada de Fourier para decompor o ECG em suas componentes de frequência, e foi calculada a densidade de energia espectral em três bandas específicas [6]:

- **Baixa Frequência (0,5–4 Hz)** – inclui parte das ondas P e T, associadas à repolarização ventricular e a componentes lentos do sinal.
- **Média Frequência (4–15 Hz)** – concentra a maior parte da energia do complexo QRS, sendo diretamente relacionada à despolarização ventricular.
- **Alta Frequência (15–40 Hz)** – carrega detalhes de alta frequência do QRS, importantes para captar sutilezas da condução elétrica cardíaca.



Todas essas features foram extraídas separadamente para cada canal de ECG selecionado no pré-processamento (II, aVL, aVF, V1, V2 e V5), o que resultou em um vetor de atributos robusto e informativo. Essa diversidade de parâmetros, combinando medidas morfológicas, temporais e espectrais, ampliou a capacidade do modelo de classificação de diferenciar padrões fisiológicos e patológicos, especialmente para as condições-alvo do estudo: infarto do miocárdio e distúrbio de condução.

## Modelo de Classificação

### Divisão do Conjunto de Dados

Para o treinamento e avaliação dos modelos de classificação, o dataset foi dividido em dois grandes conjuntos: treinamento e teste. Inicialmente, 80% das amostras foram destinadas ao conjunto de treinamento, enquanto os 20% restantes foram reservados para o conjunto de teste, utilizado apenas na etapa final para avaliação do modelo.

Do conjunto de treinamento, 20% das instâncias foram separadas para compor o conjunto de validação. Esse subconjunto teve papel fundamental no ajuste dos hiperparâmetros do modelo, como a escolha da função kernel mais adequada, o valor do parâmetro gamma e o tipo de balanceamento de classes (tema que será detalhado na seção sobre SVM). A utilização do conjunto de validação permitiu calibrar o modelo sem comprometer a avaliação final, reduzindo o risco de overfitting e garantindo que os parâmetros escolhidos fossem generalizáveis para dados não vistos.


O conjunto de teste permaneceu isolado durante todo o processo de treinamento e ajuste de hiperparâmetros. Ele foi utilizado exclusivamente para avaliar o desempenho final do modelo, fornecendo métricas sobre sua capacidade de generalizar, ou seja, de classificar

corretamente casos clínicos que não seguem exatamente a mesma distribuição do conjunto de treinamento.

Essa divisão estruturada do dataset assegurou que o modelo não sofresse overfitting, evitando um ajuste excessivo aos dados de treinamento e garantindo maior capacidade de aplicação em situações reais.

## Balanceamento do Modelo

Durante o desenvolvimento do projeto, foi observado que o conjunto de dados apresentava um desbalanceamento significativo entre as classes, conforme a figura abaixo, sendo algumas delas representadas por muito mais amostras do que outras. Esse tipo de desequilíbrio pode levar a um viés no treinamento do modelo, fazendo com que ele aprenda a prever corretamente apenas a classe majoritária, negligenciando as classes minoritárias e comprometendo a performance geral.



Para contornar esse problema, foi utilizado o parâmetro de balanceamento de classes fornecido pela biblioteca scikit-learn. Esse parâmetro atribui pesos diferentes para cada classe, proporcionalmente à sua frequência no conjunto de treinamento. Dessa forma, o modelo é incentivado a considerar igualmente todas as classes durante o processo de aprendizado, aumentando a sensibilidade em relação às classes menos representadas.

## Engenharia de Features com Random Forest

O Random Forest é um modelo de aprendizado de máquina baseado em um conjunto de árvores de decisão, onde cada árvore é treinada a partir de uma amostra aleatória dos dados e de um subconjunto aleatório das features disponíveis.

Essa abordagem permite que o modelo avalie a importância de cada feature considerando sua contribuição para a correta separação das classes ao longo das divisões internas (nós) das árvores. A importância é determinada pela redução média de impureza,

métrica que reflete o quanto uma determinada feature ajuda a diminuir a mistura de classes em cada divisão.

No contexto deste projeto, o Random Forest foi treinado utilizando todo o conjunto de features extraídas na etapa anterior, abrangendo tanto os atributos morfológicos e temporais (como intervalos RR, durações e amplitudes das ondas, área e inclinação do segmento ST) quanto às variáveis espectrais obtidas pela análise de energia em diferentes bandas de frequência e variáveis relacionadas ao paciente como idade e sexo.

Após o treinamento, foi gerado um score de importância para cada feature. Com base nesses valores, procedeu-se à seleção das variáveis com maior pontuação, ou seja, aquelas que mais contribuíram para a distinção entre as classes do problema.

## **SVM**

O SVM é um algoritmo de aprendizado de máquina supervisionado que busca separar os pontos de diferentes classes por meio de um hiperplano linear, de forma a maximizar a margem entre as classes. Essa abordagem visa garantir que o modelo seja capaz de generalizar bem para novas amostras, minimizando erros de classificação.

Em casos onde os dados não são linearmente separáveis, o SVM utiliza funções chamadas kernels, que projetam os dados em um espaço de maior dimensão. Essa transformação permite que um hiperplano linear seja encontrado nesse novo espaço, possibilitando a separação das classes mesmo em situações complexas. Entre os kernels mais comuns estão o linear, polinomial e RBF (Radial Basis Function), sendo escolhido conforme as características dos dados e a necessidade de capturar relações não lineares entre as features.

Para lidar com o problema de classificação multiclasse presente no dataset (infarto do miocárdio, distúrbio de condução e coração normal), o SVM adotou a estratégia denominada “um contra um” (one-vs-one). Nessa abordagem, o modelo treina um classificador binário para cada par de classes possíveis, de forma que cada classificador distingue entre duas classes específicas. Durante a predição, cada instância é avaliada por todos os classificadores binários, e a classe final é determinada pelo voto majoritário entre eles. Essa técnica permite lidar de maneira eficiente com múltiplas classes, mantendo a precisão de separação mesmo em situações onde as fronteiras entre categorias são complexas.

## **Normalização de Dados**


Como o SVM realiza a classificação com base em distâncias, a magnitude dos valores das features influencia diretamente o resultado. Assim, variáveis com valores de grande magnitude tendem a ter impacto muito maior do que aquelas com valores menores, o que não é ideal para nosso problema. Para garantir que todas as features tenham a mesma importância, é necessário normalizar os dados para uma mesma escala, tornando as magnitudes comparáveis.

Para isso, foi utilizado o StandardScaler da biblioteca scikit-learn, que transforma cada feature para ter média zero e desvio padrão igual a um, padronizando todas as

variáveis. Essa normalização fez com que cada atributo contribuísse proporcionalmente para a determinação do hiperplano, garantindo que informações relevantes, morfológicas, temporais e espectrais, fossem consideradas com o mesmo peso no processo de classificação.

## Resultados

Antes de avaliar métricas mais específicas do modelo, identificamos o melhor desempenho com base na acurácia. Para isso, geramos diferentes instâncias do SVM variando a quantidade de features utilizadas no treinamento. O gráfico abaixo apresenta esse resultado: a curva azul representa a acurácia no conjunto de treinamento (considerando a porção destinada à validação para a classificação), e a curva laranja, no conjunto de teste.



Observa-se que o pico de acurácia no conjunto de teste ocorre com cerca de 200 features. A partir desse ponto, embora a acurácia no conjunto de treinamento continue aumentando, a acurácia no conjunto de teste começa a cair, um indicativo de overfitting. Isso significa que o modelo está se ajustando excessivamente aos dados de treino, perdendo capacidade de generalizar para novos casos.

## Métricas de Avaliação

Ao desenvolver e testar modelos de classificação, não basta analisar apenas a acurácia geral, pois ela pode ser enganosa em conjuntos de dados desbalanceados. Por isso, utilizamos métricas mais específicas para avaliar o desempenho do modelo de forma detalhada: precision, recall e F1 score.

A precision (precisão) é o número de exemplos que seu modelo previu como positivos e acertou dividido pelo número total de exemplos que ele previu como positivos.

$$Precisão = \frac{Positivos\ Verdadeiros}{Positivos\ Verdadeiros + Falsos\ Positivos}$$




O recall é o número de pessoas que o modelo identificou corretamente como tendo a classe dividida pelo número total de pessoas que realmente têm a classe nos seus dados.

$$Recall = \frac{Positivos\ Verdadeiros}{Positivos\ Verdadeiros + Negativos\ Falsos}$$

O F1 Score é a média harmônica entre a precisão e o recall. A média harmônica é usada porque ela dá mais importância a valores baixos, o que faz sentido, pois um valor muito mais baixo de precisão ou recall indica que o modelo não está equilibrando bem essas duas métricas, quando se quer dar importância igual às duas.

$$F1\ Score = 2 * \frac{Precisão * Recall}{Precisão + Recall}$$


## Treinamento



|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| CD           | 0.76      | 0.72   | 0.74     | 219     |
| MI           | 0.63      | 0.55   | 0.58     | 278     |
| NORM         | 0.90      | 0.93   | 0.91     | 1437    |
| accuracy     |           |        | 0.85     | 1934    |
| macro avg    | 0.76      | 0.73   | 0.74     | 1934    |
| weighted avg | 0.84      | 0.85   | 0.85     | 1934    |

A partir da análise da matriz de confusão e das métricas de avaliação, observa-se que o modelo apresentou alto desempenho na identificação de registros normais, com valores elevados para as três métricas consideradas. Para a classe de distúrbio de condução, os resultados foram razoáveis, enquanto a detecção de infarto do miocárdio apresentou menor eficácia. O caso mais crítico ocorreu nos falsos negativos da classe normal, em que o modelo classificou como normal um paciente que, na realidade, estava doente, sendo registrada uma quantidade considerável dessas ocorrências.

## Teste



|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| CD           | 0.73      | 0.70   | 0.72     | 274     |
| MI           | 0.65      | 0.65   | 0.65     | 348     |
| NORM         | 0.91      | 0.92   | 0.91     | 1795    |
| accuracy     |           |        | 0.85     | 2417    |
| macro avg    | 0.76      | 0.76   | 0.76     | 2417    |
| weighted avg | 0.85      | 0.85   | 0.85     | 2417    |

A análise dos resultados de teste indica que o modelo com 200 features apresentou o melhor equilíbrio entre as três classes, reduzindo as confusões mais críticas observadas anteriormente, especialmente na detecção de infarto do miocárdio, apresentando uma boa generalização. Apesar disso, a acurácia em relação às doenças mais graves permaneceu insatisfatória, o que, embora mitigue o impacto dos falsos negativos para essa condição grave, ainda não proporciona segurança suficiente para uso em situações de emergência.

## Conclusão

O projeto atingiu o objetivo de detectar anomalias cardíacas em ECG, apresentando bons resultados para distúrbios de condução e desempenho moderado na detecção de infarto do miocárdio. Uma possível explicação para esse desempenho é que a subclasse de infarto do miocárdio engloba diversas variações de tipos específicos, o que dificulta a definição de um padrão geral na superclasse.

Apesar de apresentar acurácia baixa para o infarto do miocárdio, condição mais crítica, o modelo obteve excelente acurácia na identificação de pacientes normais. Isso indica que, para um cenário crítico como o de emergência, sua aplicação não seria adequada, pois há risco de pacientes doentes serem classificados como normais. No entanto, em contextos de triagem ou atendimentos de urgência, nos quais o objetivo é identificar se o paciente está saudável e sem risco imediato de vida, o modelo se mostra bastante promissor, dado seu bom desempenho na previsão de casos normais.

Para trabalhos futuros, recomenda-se ampliar e balancear o dataset, explorar técnicas de data augmentation, refinar o processo de extração de features, visando melhorar o desempenho especialmente na detecção de infarto do miocárdio. Essas melhorias podem aproximar o modelo de um uso clínico mais abrangente e seguro.

## Referências

- [1]: [PTB-XL, a large publicly available electrocardiography dataset v1.0.3](#)
- [2]: [‘Estamos vivendo uma epidemia de arritmias cardíacas’, alerta cardiologista Eduardo Saad](#)
- [3]: [Infarto — Ministério da Saúde](#)
- [4]: [Automated Detection of Myocardial Infarction and Heart Conduction Disorders Based on Feature Selection and a Deep Learning Model](#)
- [5]: [Machine learning models for classification of myocardial infarction using the PTB-XL dataset](#)
- [6]: [Comparison of Power Spectral Density \(PSD\) of Normal and Abnormal ECGs](#)